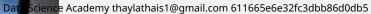






Seja muito bem-vindo(a)!







K Nearest Neighbors









Conhecendo o Algoritmo KNN






- 1- Dados de Treinamento
- 2- Definir a métrica para cálculo da distância
- 3- Definir o valor de K (número de vizinhos mais próximos que serão considerados pelo algoritmo)






Cálculo da distância entre
o exemplo desconhecido
e o outros exemplos do
conjunto de treinamento














Outras formas de medir a distância:

- Distância Manhattan
- Distância de Minkowsky
- Distância de Hamming



Os dados devem estar normalizados antes de aplicar o algoritmo.









KNN e Estrutura de Células de Voronoi






A pergunta que queremos responder é: a qual dos 2 grupos o ponto amarelo com a interrogação pertence?






O algoritmo KNN utiliza medidas de distância a fim de comparar os pontos de dados.






Se usamos um valor de K igual a 3, o KNN vai comparar o novo ponto de dado com os 3 vizinhos mais próximos em cada classe e então fazer uma votação.






Célula Voronoi






O tamanho de cada célula é determinado pelo número de exemplos disponíveis no dataset de treino.











Um aspecto interessante dessa separação por células é que existe uma fronteira que forma a separação entre as classes de dados.












Como funciona o KNN




Atributos (variáveis preditoras)

Classe (variável target)

Como classificar um novo ponto de dado X


- 1- A distância é computada entre X e Xi para cada valor de Xi.
- 2- É escolhido o k-vizinho mais próximo Xin e sua respectiva classe.
- 3- Retorna-se o valor de y mais frequente na lista yi1, yi2, ..., yin.





Valor de K







Existem diversas medidas de distância disponíveis e vamos discutir aqui algumas das mais comuns. O principal propósito da medida de distância é identificar os dados que são similares e que não são similares.



Assim como o valor de K, a medida de distância influencia diretamente a performance de modelos criados com o KNN.



Distância Euclidiana

$$D(a,b) = \sqrt{\sum_{i=1}^{n} (b_i - a_i)^2}$$





Distância de Hamming

$$D_H = \sum_{i=1}^k |x_i - y_i|$$

$$x = y \Rightarrow D = 0$$

$$x = y \Rightarrow D = 0$$
$$x \neq y \Rightarrow D = 1$$




Distância de Minkowski

$$\sum_{i=1}^{k} \left(\left| x_i - y_i \right| \right)^q$$











As distâncias Manhattan e Euclidiana são as mais comuns.






A precisão da classificação utilizando o algoritmo KNN depende fortemente do modelo de dados. Na maioria das vezes os atributos precisam ser normalizados para evitar que as medidas de distância sejam dominadas por um único atributo.





O algoritmo KNN é uma variação do algoritmo NN.









KNN

Vantagens e Desvantagens





Vantagens

- Rápido treinamento
- Capaz de aprender funções complexas
- Não perde/desperdiça informação
- Bastante flexível
- Em alguns casos pode apresentar bons resultados





Desvantagens

- Classificar um exemplo desconhecido pode ser um processo computacionalmente complexo, pois requer um cálculo de distância para cada exemplo de treinamento
- Lento para realizar uma consulta
- A precisão da classificação pode ser severamente degradada pela presença de ruído ou características irrelevantes
- Não constrói um modelo de classificação



