







Redes Neurais Artificiais Profundas (Deep Learning)




Machine Learning



Deep Learning









Este capítulo será uma introdução a Deep Learning, pois esse é um tema bastante extenso!





O Que é Deep Learning?










Deep Learning é uma subcategoria de Machine Learning.



Simple Neural Network

Deep Learning Neural Network








O Processo de Aprendizagem de Modelos de Deep Learning





Basic features

Embeddings

Convolution


Max pooling

"Supervised" learning

Em Deep Learning nosso trabalho é preparar as estruturas de dados.


O aprendizado de recursos e a classificação/regressão são ambos feitos pelo modelo.






Em Visão Computacional, primeiro a rede realiza o processo de aprendizagem dos recursos e depois faz a classificação.





A aprendizagem ocorre em duas etapas: Forward Propagation e Backward Propagation!











Arquitetura de Redes Neurais Convolucionais








Transformamos a Matriz em Vetor













Arquitetura de Redes Neurais Recorrentes







Feed Forward Network




Output Layer


Hidden Layer


Input Layer

Recurrent Network















Data Science Academy

LSTM Long Short-Term Memory



















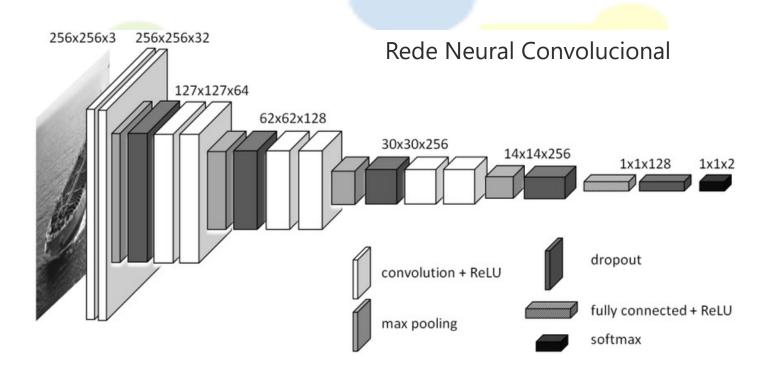





Data Science Academy

Por Que Usamos a Função Softmax?



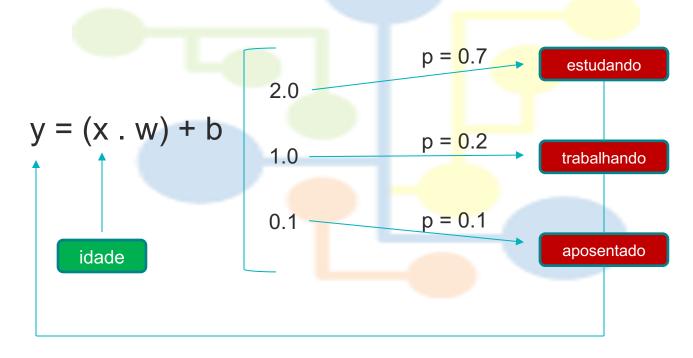









Classificador Logístico









Função Softmax

Scores

Probabilidades

Logits



Função Softmax

```
import numpy as np
scores = [3.0, 1.0, 0.2]

def softmax(x):
    return np.exp(x) / np.sum(np.exp(x), axis = 0)

print(softmax(scores))

[ 0.8360188     0.11314284     0.05083836]
```



Função Softmax


$$P(y=j \mid \boldsymbol{\Theta}^{(i)}) = \frac{\mathbf{e}^{\boldsymbol{\Theta}^{(i)}}}{\sum_{j=0}^{k} \mathbf{e}^{\boldsymbol{\Theta}^{(i)}_{k}}}$$
where $\boldsymbol{\Theta} = w_{o}x_{o} + w_{1}x_{1} + ... + w_{k}x_{k} = \sum_{j=0}^{k} w_{i}x_{j} = w^{T}x$






Afinal, O Que é Hot Encoding?










S(y) = Função Softmax que converte os scores para probabilidades



Hot Encoding









Otimização com Stochastic Gradient Descent






O treinamento de uma rede neural é convertido em um problema de otimização, cujo objetivo é minimizar o erro cometido pela rede, quando considerados todos os exemplos de treinamento.










$$J(f(x(t); \theta), y(t))$$




O gradiente de uma função f mede o quanto f varia uma vez que seus argumentos são alterados. Se f for uma função multivariada de n variáveis, então ∇ f é um vetor n-dimensional cujas componentes são as derivadas parciais de f.






Além de ser computacionalmente intensivo, com Gradient Descent você precisa calcular o gradiente de cada elemento do seu conjunto de treinamento, o que pode levar muito tempo em grandes conjuntos de dados.






A solução encontrada para esse problema, foi o Stochastic Gradient Descent (SGD) que é uma versão do Gradient Descent, em que trabalhamos com amostras aleatórias.





SGD é uma aproximação de Gradient
Descent e quanto mais lotes
processados pela rede neural (ou
seja, mais amostra aleatórias), melhor
a aproximação.






A implementação do SGD compreende:

- Amostragem aleatória de um lote de dados do conjunto de dados total.
- 2. Executar a rede para frente e para trás para calcular o gradiente (com dados gerados no item 1).
- 3. Aplicar a atualização de descida de gradiente.
- 4. Repetir os passos 1 a 3 até que a convergência ou o ciclo seja interrompido por outro mecanismo, ou seja, o número de épocas (epochs).





A técnica de Stochastic Gradient Descent está no cerne do Deep Learning.

Isso ocorre porque o SGD se equilibra bem com os dados e o tamanho do modelo, e queremos trabalhar com Big Data e modelos com muitas camadas ocultas.

